

Predicción de Abandono, Matriculación y Graduación de Estudiantes

Proyecto de Machine Learning — ML_RENDIMIENTO

Este informe documenta el proceso completo seguido para construir un modelo de clasificación que predice, en el momento de la matrícula, si un estudiante universitario terminará en situación de **Dropout** (abandono), **Enrolled** (sigue matriculado) o **Graduate** (se gradúa).

1. Business Case y Definición del Problema

Business understanding

Las universidades quieren identificar, **en el momento de la matrícula**, qué estudiantes tienen mayor riesgo de abandonar los estudios, para poder activar medidas de apoyo tempranas: becas, tutorías, planes de pago flexibles o seguimiento académico reforzado.

Hipótesis y objetivo de modelado

Problema **supervisado de clasificación multiclase** (3 clases): *Dropout*, *Enrolled* y *Graduate*. La variable target es **Target**.

Plan de acción

El modelo entrenado se usaría para generar, para cada estudiante recién matriculado, una probabilidad de pertenecer a cada clase. El equipo de orientación académica priorizaría el contacto con los estudiantes de mayor probabilidad de *Dropout*.

Requerimientos y adquisición de datos


Dataset público de rendimiento académico: 4424 registros y 37 columnas (36 variables + target), sin valores nulos. Variables sociodemográficas, académicas previas, económicas y de trayectoria curricular por semestre.

2. Dataset y Análisis Exploratorio (EDA)

Exploratorio inicial

4424 filas × 37 columnas. **0% de valores nulos** en todas las columnas. 18 variables numéricas y 18 categóricas, según una tipificación manual basada en el diccionario del dataset (la función automática de tipificación clasificaba mal varias columnas por depender solo de la cardinalidad y no del significado real de cada variable).

Distribución del target



Graduate 49.9% · Dropout 32.1% · Enrolled 17.9%. Desbalance moderado: la clase minoritaria (Enrolled) requiere atención especial y descarta el uso de accuracy como métrica principal.

Alerta de data leakage

Las 12 variables *Curricular units 1st/2nd sem* (*) muestran una relación extrema con el target (F-estadístico ANOVA de hasta 1410), porque describen resultados académicos posteriores a la matrícula. La mediana de asignaturas aprobadas en 2º semestre es **0 para Dropout** y **6 para Graduate**:

Target	Mediana aprobadas 2º sem.
Dropout	0.0
Enrolled	4.0
Graduate	6.0

Estas variables además están muy correlacionadas entre sí ($r=0.94$ en credited/enrolled 1º vs 2º semestre, $r=0.90$ en approved), por lo que ni siquiera aportarían 12 señales independientes si se usaran parcialmente.

ANOVA (numéricas) y Chi-cuadrado (categóricas) vs Target

17 de 18 numéricas y 15 de 18 categóricas muestran relación significativa con el target ($p<0.05$). Variables numéricas "limpias" (sin leakage) más relevantes: **Age at enrollment** ($F=154.71$), **Admission grade** ($F=35.65$), **Previous qualification (grade)** ($F=27.73$). Variables categóricas más relevantes: **Tuition fees up to date** ($\chi^2=823.55$), **Scholarship holder** ($\chi^2=409.94$), **Debtor** ($\chi^2=259.33$) — la situación económica del estudiante emerge como uno de los factores más determinantes.

No significativas: *Inflation rate* ($p=0.175$), *Educational special needs* e *International* (muy pocos casos positivos), y *Nationality* ($p=0.242$, aunque poco fiable porque el 97.5% de estudiantes comparten una única nacionalidad).

Multicolinealidad entre numéricas

Los pares de variables más correlacionados son, casi en su totalidad, del bloque *Curricular units* (correlaciones entre 0.68 y 0.94), confirmando que son redundantes entre sí además de sufrir leakage:

Variable A	Variable B	r
Curricular units 2º sem (credited)	Curricular units 1º sem (credited)	0.945
Curricular units 2º sem (enrolled)	Curricular units 1º sem (enrolled)	0.943
Curricular units 2º sem (approved)	Curricular units 1º sem (approved)	0.904
Curricular units 1º sem (grade)	Curricular units 2º sem (grade)	0.837
Curricular units 2º sem (evaluations)	Curricular units 1º sem (evaluations)	0.779

3. Selección de Variables y Feature Engineering

Con el objetivo de negocio de actuar **lo antes posible**, el modelo final se construye **únicamente con variables disponibles en el momento de la matrícula**, excluyendo por completo las 12 variables de *Curricular units*.

Variables descartadas (16)

- Las 12 variables *Curricular units 1st/2nd sem (*)* — data leakage.
- *Nationality, Educational special needs, International, Inflation rate* — no significativas en el EDA.

Variables finales del modelo (20)

Datos sociodemográficos, académicos previos y económicos disponibles en matrícula: estado civil, vía y orden de acceso, curso, turno, cualificación previa y de los padres, ocupación de los padres, nota de admisión, situación económica (Displaced, Debtor, Tuition fees up to date, Scholarship holder), género, edad de matriculación, y los indicadores macroeconómicos de cohorte (Unemployment rate, GDP).

Coste cuantificado de excluir el leakage

Para dejar constancia razonada del trade-off, se comparó el F1 macro (CV, Logistic Regression) con y sin las variables de *Curricular units*:

Escenario	F1 macro (CV)
Con Curricular units (leakage)	0.713
Sin Curricular units (final)	0.566

Incluir esas variables infla artificialmente el rendimiento (el modelo básicamente "ve" el resultado académico antes de predecirlo). Se confirma la decisión: el pipeline final prioriza un modelo honesto y útil para intervención temprana sobre uno con métrica más alta pero poco realista en producción.

4. Preprocesado

División train/test: 80/20 estratificada por Target (3539 filas train, 885 test), realizada antes de cualquier ajuste para no contaminar la evaluación final.

ColumnTransformer con tres grupos de columnas:

- **Numéricas** (5: notas, edad, indicadores macro) → StandardScaler.
- **Nominales** (10: estado civil, curso, cualificaciones/ocupación de padres...) → OneHotEncoder (handle_unknown='ignore').
- **Binarias** (5: ya en 0/1) → passthrough.

5. Modelado

Métrica de evaluación


F1 macro, elegida por el desbalance moderado del target: accuracy premiaría ignorar la clase minoritaria (Enrolled).

Modelo baseline

DummyClassifier (clase mayoritaria) → F1 macro (CV) = **0.222**, como suelo de referencia mínimo.

Comparativa de algoritmos

4 algoritmos con `class_weight='balanced'`, validación cruzada estratificada de 5 folds:



F1 macro por modelo, comparado con el baseline (línea roja).

Estrategia de balanceo: `class_weight` vs SMOTE

`class_weight='balanced'` (F1=0.569) vs SMOTE (F1=0.571): diferencia dentro del ruido de la CV. Se elige **`class_weight='balanced'`** por ser más simple y no generar observaciones sintéticas (evita sobreajustar a vecinos artificiales en variables categóricas de alta cardinalidad tras el one-hot).

Selección del modelo a optimizar

SVM y Logistic Regression obtienen el mejor F1 macro, muy por encima del resto. Se elige **Logistic Regression**: rendimiento prácticamente idéntico al de SVM pero mucho más rápida de entrenar/tunear y, sobre todo, **interpretable** — clave para que el equipo de orientación académica entienda *por qué* un estudiante está en riesgo.

Optimización de hiperparámetros


RandomizedSearchCV (25 iteraciones, F1 macro, CV estratificada 5-fold) sobre la fuerza de regularización C. Mejor resultado: **F1 macro (CV) = 0.575**, con $C \approx 0.191$.

6. Evaluación Final

Evaluación única sobre el conjunto de test (885 estudiantes), nunca antes tocado.

F1 macro (test) ≈ 0.575 , en línea con la validación cruzada y sin señales de sobreajuste.

Matriz de confusión




El modelo separa razonablemente bien Dropout y Graduate (precision/recall entre 0.58 y 0.72). Enrolled es, con diferencia, la clase más difícil: representa estudiantes cuya trayectoria aún no está definida en el momento de matrícula, lo cual es coherente con la naturaleza del problema y no un fallo del modelo.

Métrica clave de negocio: recall de Dropout

De los 284 estudiantes que realmente abandonan en el conjunto de test, el modelo detecta correctamente 167 (recall ≈ 0.59). Es la cifra que determina cuántos estudiantes en riesgo real recibirían apoyo si se desplegara este modelo.

Interpretabilidad: variables más influyentes para Dropout



Confirma lo observado en el EDA: la situación económica (*Tuition fees up to date*, *Scholarship holder*) y ciertas modalidades de acceso/curso y ocupación de los padres concentran buena parte del peso predictivo sobre el riesgo de abandono.

Persistencia del modelo

El pipeline completo (preprocesado + Logistic Regression, ya entrenado sobre todo train) se guarda con `joblib.dump()` en `src/notebooks/src/models/modelo_dropout_final.joblib`, listo para producción sin necesidad de repetir el preprocesamiento manualmente.

7. Conclusiones y Próximos Pasos

Resumen del proceso

- Se descartaron las variables Curricular units por data leakage, priorizando un modelo útil para intervención temprana frente a uno con métricas infladas.
- F1 macro como métrica principal por el desbalance moderado de clases; `class_weight='balanced'` como estrategia de balanceo (equivalente a SMOTE, pero más simple).
- Logistic Regression elegida por rendimiento a la par del mejor modelo (SVM) pero con la ventaja de ser interpretable y más rápida de ajustar.
- F1 macro final en test ≈ 0.575 , sin señales de sobreajuste respecto a CV.

Limitaciones

- La clase Enrolled sigue siendo difícil de predecir, algo esperable dado que representa una situación aún no resuelta en el momento de la matrícula.
- El modelo no usa ningún dato posterior a la matrícula; un sistema de alerta temprana en producción podría combinarse con un segundo modelo (datos de 1er semestre) para recalibrar el riesgo a mitad de curso, asumiendo conscientemente el leakage/ventana temporal más corta que eso implica.

Posibles mejoras futuras

- Ensamblado (stacking) de Logistic Regression + SVM, dado que ambos capturan patrones ligeramente distintos según la matriz de confusión.

- Ingeniería de variables combinando cualificación + ocupación de padre/madre para resumir el capital socioeconómico familiar y reducir la dimensionalidad del one-hot.